

实验一：手写数字识别

基于卷积神经网络的 MNIST 分类

尧祥临 202518023406038

中国科学院大学 前沿交叉科学学院
2026 年春季学期 深度学习

实验任务

目标

在 MNIST 手写数字数据集上构建并训练卷积神经网络，实现 0 到 9 共 10 类数字图象分类。

实验要求

- 使用 PyTorch 完成数据加载、模型构建与训练
- 搭建规范的 CNN 网络结构
- 测试集准确率达到 98% 及以上

本次完成情况

- 训练 20 个 epoch
- 保存训练日志和模型参数
- 最终测试集准确率：**99.33%**

数据集与划分


- 数据集: MNIST 手写数字数据集
- 输入尺寸: $1 \times 28 \times 28$ 灰度图象
- 类别数: 10 类, 对应数字 0 到 9
- 输入预处理: `transforms.ToTensor()`

划分	样本数
训练集	55000
验证集	5000
测试集	10000

划分方式

从原始 60000 张训练图象中随机划分 55000 张用于训练, 5000 张用于验证; 测试集保持官方 10000 张不变。

整体流程




训练阶段

- `model.train()`
- 前向传播、反向传播、参数更新

评估阶段

- `model.eval()`
- 计算 loss 和 accuracy

CNN 模型结构



卷积与池化

两个卷积层均采用 5×5 卷积核、stride 1、padding 2；最大池化采用 2×2 、stride 2。

分类头

将 $64 \times 7 \times 7$ 特征图展平为 3136 维向量，经过 128 维隐藏层后输出 10 类 logits。

结构设计分析

为什么使用浅层 CNN

MNIST 图像分辨率小、背景简单，类别差异主要来自局部笔画和整体轮廓；两层卷积已经能够覆盖从边缘到笔画组合的特征层次。

- 5×5 卷积覆盖较宽局部笔画区域
- padding 2 保持空间尺寸，减少边缘信息丢失
- ReLU 引入非线性表达能力

池化与分类头

最大池化将 $28 \rightarrow 14 \rightarrow 7$ ，在压缩空间尺寸的同时增强小幅平移鲁棒性；全连接层利用粗略空间分布完成类别判别。

- 第二层卷积组合更抽象的笔画结构
- 3136 维特征保留局部结构分布
- 参数主要集中在第一个全连接层

模型核心代码

```
class CNN(nn.Module):
    def __init__(self, hidden_dim=128):
        super(CNN, self).__init__()
        self.conv1 = nn.Conv2d(1, 32, kernel_size=5, stride=1, padding=2)
        self.relu1 = nn.ReLU()
        self.pool1 = nn.MaxPool2d(kernel_size=2, stride=2)

        self.conv2 = nn.Conv2d(32, 64, kernel_size=5, stride=1, padding=2)
        self.relu2 = nn.ReLU()
        self.pool2 = nn.MaxPool2d(kernel_size=2, stride=2)

        self.fc = nn.Sequential(
            nn.Flatten(),
            nn.Linear(64 * 7 * 7, hidden_dim),
            nn.ReLU(),
            nn.Linear(hidden_dim, 10)
        )

    def forward(self, x):
        x = self.pool1(self.relu1(self.conv1(x)))
        x = self.pool2(self.relu2(self.conv2(x)))
        return self.fc(x)
```

参数量与尺寸变化

层	输出尺寸	参数量
Conv1	$32 \times 28 \times 28$	832
Conv2	$64 \times 14 \times 14$	51264
Linear1	128	401536
Linear2	10	1290
总计	—	454922

尺寸计算

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + 2P - K}{S} \right\rfloor + 1$$

- padding 2 保持卷积前后尺寸不变
- 两次最大池化将 $28 \rightarrow 14 \rightarrow 7$
- 参数主要集中在第一个全连接层

项目	设置
Batch size	64
Epochs	20
Learning rate	5×10^{-4}
隐藏层维度	128
优化器	AdamW
损失函数	CrossEntropyLoss
训练设备	CUDA GPU

损失函数

$$\mathcal{L} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(z_{i,y_i})}{\sum_{c=0}^9 \exp(z_{i,c})}$$

- 每个 epoch 后记录验证集和测试集指标
- 训练日志保存为 `train_log.csv`
- 模型参数保存为 `cnn_mnist.pth`



训练结果

Epoch	Train Loss	Val Loss	Val Acc	Test Loss	Test Acc
1	0.2084	0.0680	97.78%	0.0518	98.32%
5	0.0235	0.0384	98.80%	0.0321	98.86%
10	0.0087	0.0326	99.18%	0.0308	99.19%
15	0.0031	0.0319	99.14%	0.0297	99.23%
19	0.0026	0.0267	99.32%	0.0310	99.31%
20	0.0022	0.0289	99.20%	0.0312	99.33%

观察


第 1 个 epoch 后测试准确率已经达到 98.32%，超过实验要求；训练到第 20 个 epoch 后测试准确率提升到 99.33%。

训练曲线



- 训练损失在前几个 epoch 快速下降，随后逐渐收敛
- 测试准确率整体位于 99% 附近并继续提升
- 第 16 个 epoch 附近存在一次波动，但后续恢复到较低 loss 和较高 accuracy

混淆矩阵分析



整体表现

测试集共 10000 张图象，正确分类 9933 张，错误分类 67 张，准确率为 **99.33%**。

- 混淆矩阵对角线占主导，各类别识别稳定
- 召回率相对最低的是数字 9，约为 98.61%
- 最大混淆：9 → 4，共 6 次

错误类型分析

主要错误模式

剩余错误主要出现在形态相近的数字之间，而不是某一类整体失效。

- 9 → 4: 6 次
- 5 → 3: 5 次
- 9 → 5: 5 次
- 7 → 2: 4 次

原因解释

手写体的闭合程度、倾斜角度和笔画连接方式会改变数字轮廓，例如 9 的上半部分不明显时容易接近 4，5 和 3 都包含右侧弧形结构。

- 错误具有可解释的形态相似性
- 当前模型没有表现出明显类别偏置
- 可通过轻量几何增强继续改善鲁棒性

总结

完成内容

本次实验基于 PyTorch 完成了 MNIST 手写数字识别，包括数据加载与划分、CNN 模型搭建、训练评估、日志记录、模型保存、训练曲线可视化和混淆矩阵分析。

主要收获

进一步熟悉了卷积、激活、池化和全连接分类头的配合方式，也观察到 CNN 对局部笔画特征、空间下采样和类别判别的建模过程。

可改进方向

固定随机种子增强复现性；加入输入标准化；使用轻量几何增强提升模型对不同书写倾斜角度和笔画位置的鲁棒性。