

实验二：基于 ViT 的 CIFAR10 图像分类

Vision Transformer on CIFAR10

尧祥临 202518023406038

中国科学院大学 前沿交叉科学学院
2026 年春季学期 深度学习

实验任务

目标

从零实现一个基于 ViT 的 CIFAR10 图像分类模型，完成数据读取、网络构建、模型训练和测试评估。

实验要求

- 使用深度学习框架完成完整训练流程
- 构建 ViT 模型和 Attention 结构
- 测试集准确率达到 80% 以上

本次结果

- 训练日志共 176 个 epoch
- 最高测试准确率: **85.79%**
- 验证最优模型测试准确率: **85.61%**

数据集与划分


- 数据集: CIFAR10
- 图像尺寸: $3 \times 32 \times 32$
- 类别数: 10 类
- 训练增强: RandomCrop、RandomHorizontalFlip、RandomErasing
- 归一化: CIFAR10 mean/std

划分	样本数
训练集	45000
验证集	5000
测试集	10000

划分方式

使用固定随机种子 114514 从官方训练集中划分训练集和验证集, 官方测试集保持不变。

整体流程




训练阶段

- Mixup + label smoothing
- 梯度裁剪与 DropPath 正则化

评估阶段

- 使用 EMA 模型计算验证/测试指标
- 按验证集准确率保存最优模型

ViT 模型结构



Patch 划分

32×32 图像使用 4×4 patch, 因此得到 $8 \times 8 = 64$ 个 patch token。

分类方式

Transformer 输出后, 对 patch token 求均值, 再送入线性分类头输出 10 类 logits。

Patch Embedding 核心代码

```
class Embedding(nn.Module):
    def __init__(self, image_size=32, patch_size=4,
                  in_channels=3, embed_dim=256):
        super().__init__()
        self.num_patches = (image_size // patch_size) ** 2
        self.embedding = nn.Sequential(
            nn.Conv2d(in_channels, embed_dim,
                      kernel_size=patch_size,
                      stride=patch_size,
                      bias=False),
            nn.Flatten(2)
        )

    def forward(self, x):
        output = self.embedding(x)
        output = output.transpose(1, 2)
        return output
```

Transformer Encoder

Self-Attention

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- embedding dim = 256
- heads = 8
- 每个 head 维度为 32

Encoder Layer

- LayerNorm + MultiheadAttention
- 残差连接 + DropPath
- LayerNorm + MLP
- MLP hidden dim = 1024

模型规模与训练配置

模块	参数量
Patch Embedding	12288
Transformer Encoder	6318080
Classification Head	2570
总计	6350346

项目	设置
Batch size	128
Learning rate	4×10^{-4}
Weight decay	2×10^{-2}
Depth / Heads	8 / 8
Drop path	0.1
Epochs	176 early stop

数据与损失

- RandomCrop + RandomHorizontalFlip
- RandomErasing
- Mixup, $\alpha = 0.2$
- Label smoothing = 0.05

优化与稳定性

- AdamW 分组权重衰减
- EMA decay = 0.9998
- Warmup + CosineAnnealingLR
- Gradient clipping = 1.0



训练结果：关键节点

Epoch	Val Acc	Test Acc	说明
50	79.58%	80.59%	已达到实验要求
100	84.58%	85.12%	进入稳定提升阶段
131	85.46%	85.79%	测试集准确率最高
136	85.68%	85.61%	验证集准确率最高
176	85.32%	85.57%	early stopping 停止训练

结论



验证集最优点与测试集最优点很接近，说明验证集选择没有明显偏离测试趋势。

训练曲线




- 前 50 个 epoch 完成主要拟合，测试准确率达到 80.59%
- 50 至 130 个 epoch 继续缓慢提升，最终稳定在 85% 附近
- 训练 loss 后期波动主要来自 Mixup 和随机增强，不代表验证性能退化

学习率与泛化差距



- warmup 后余弦退火衰减
- 测试/验证准确率差距整体较小
- 第 131 和 136 个 epoch 指标接近, 模型选择较稳定

结果分析



为什么能超过 80%

- 4×4 patch 保留较充分的局部细节
- Mixup、RandomErasing、DropPath 共同抑制过拟合
- EMA 与余弦退火提升后期评估稳定性

后期提升变慢

模型容量足够，限制主要来自小数据集上的泛化能力；继续训练的收益小于增强和正则化调参。

总结

完成内容

本次实验完成了基于 ViT 的 CIFAR10 分类，包括数据增强、Patch Embedding、Transformer Encoder、训练策略、模型保存和日志可视化。

主要收获

实践了将图像切分为 patch token 并送入 Transformer 的流程，也进一步理解了多头自注意力、位置编码、DropPath、Mixup、EMA 和学习率调度的作用。

可改进方向

可以继续尝试更强的数据增强、更长训练、更细的 patch 大小或更系统的正则化参数搜索。