

实验三：自动写诗

基于 LSTM 语言模型的唐诗生成

尧祥临 202518023406038

中国科学院大学 前沿交叉科学学院
2026 年春季学期 深度学习

实验任务

目标

基于预处理后的唐诗数据集训练字符级语言模型，实现给定首句后的自动续写，并进一步实现藏头诗生成。

实验要求

- 完成数据读取、网络设计、模型训练和测试
- 给定首句后生成尽可能自然的诗句
- 网络结构设计需要有自己的方案

本次完成情况

- 训练两层 LSTM 字符级语言模型
- 最优验证困惑度：**98.17**
- 支持普通续写与五言/七言藏头诗

数据集与预处理

- 数据集：预处理后的唐诗数据集
- 词表大小：8293
- 每首诗原始固定长度：125
- 特殊 token：<START>、<EOP>、</s>
- 验证集比例：10%

预处理策略

定位 <START>，去除前导 padding；保留到 <EOP> 的真实诗句内容；超长截断，不足则右侧填充 </s>。

损失处理

训练时使用 `ignore_index` 忽略 padding 位置，使模型主要学习真实诗句中的字符转移。

整体流程



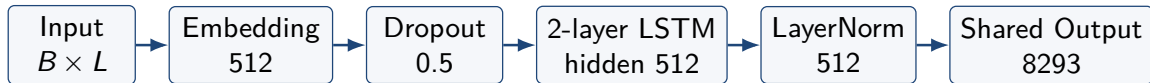
训练阶段

- 输入第 0 到 $n - 1$ 个 token
- 预测第 1 到 n 个 token

生成阶段

- 首句强制喂入模型
- 后续字符使用 top-p 采样

模型结构



上下文建模

两层 LSTM 用于学习诗句内部的字符依赖关系，Embedding dropout 和层间 dropout 用于正则化。

输出层设计

输出投影与输入 Embedding 共享权重，只额外学习词表大小的 bias，减少参数并保持表示空间一致。

模型核心代码

```
class PoetryModel(nn.Module):
    def __init__(self, vocab_size, embedding_dim=512,
                  hidden_dim=512, num_layers=2,
                  dropout=0.5, padding_idx=None):
        super().__init__()
        self.embedding = nn.Embedding(
            vocab_size, embedding_dim, padding_idx=padding_idx
        )
        self.emb_dropout = nn.Dropout(dropout)
        self.lstm = nn.LSTM(
            embedding_dim, hidden_dim,
            num_layers=num_layers,
            batch_first=True,
            dropout=dropout
        )
        self.norm = nn.LayerNorm(hidden_dim)
        self.output_bias = nn.Parameter(torch.zeros(vocab_size))

    def forward(self, x, hidden=None):
        embeds = self.emb_dropout(self.embedding(x))
        output, hidden = self.lstm(embeds, hidden)
        output = self.norm(output)
        output = F.linear(output, self.embedding.weight, self.output_bias)
        return output.reshape(x.size(0) * x.size(1), -1), hidden
```

训练配置

项目	设置
Batch size	128
Epochs	60
Embedding dim	512
Hidden dim	512
LSTM layers	2
Dropout	0.5

项目	设置
Optimizer	AdamW
Learning rate	1×10^{-3}
Weight decay	1×10^{-4}
Warmup	3 epochs
Scheduler	Cosine annealing
Gradient clip	1.0

评价指标

训练和验证阶段记录 loss 与 perplexity, perplexity 定义为 $\text{PPL} = \exp(\mathcal{L})$ 。



训练结果

Epoch	Train Loss	Train PPL	Val Loss	Val PPL
1	17.1580	28289150.5	7.2008	1340.5
3	6.0091	407.1	5.7344	309.3
10	5.2267	186.2	5.0532	156.5
20	4.9798	145.4	4.8341	125.7
40	4.7265	112.9	4.6369	103.2
60	4.6504	104.6	4.5867	98.2

最终结果



- 最佳 epoch: 60
- 验证 loss: 4.5867
- 验证 PPL: **98.17**
- 梯度范数: 0.556

训练曲线



- 前几轮 loss 与 perplexity 快速下降，模型学习到高频字、常见词组和标点模式。
- 后期仍缓慢改善，但开放式文本生成存在大量合理后继字符，困惑度不会下降到分类任务那样低。

学习率与梯度范数



- 前 3 轮 warmup 让模型平稳进入训练。
- 后续余弦退火逐渐降低学习率，训练后期更新更细。
- 梯度范数从第 1 轮的较大值快速下降，说明梯度裁剪和调度策略能控制 RNN 训练不稳定性。

生成流程

- ① 用 <START> 初始化 hidden state
- ② 首句字符逐个强制喂入模型
- ③ 首句结束后根据 logits 采样下一个字
- ④ 将生成字继续作为下一步输入

Top-p 采样

按照概率从高到低累积，只保留累计概率不超过 p 的候选集合，再从截断分布中随机采样。

- temperature = 0.7
- top-p = 0.9
- 相比 greedy decoding 更不单调

普通续写输出

首句：湖光秋月两相和

湖光秋月两相和，落日江南一半愁。

首句：白日依山尽

白日依山尽，青山万里平。天寒云外出，水阔楚山低。流水逢归客，春风入竹林。明朝更惆怅，更寄旧时人。

首句：海上生明月

海上生明月，还应忆九天。春风开露叶，玉树含芳菲。今日湖中月，同来旧思君。

- 局部词组和意象较自然，但长距离主题递进仍然较弱。

藏头诗生成策略

为什么要单独设计

普通生成允许模型自由决定句长和标点，容易出现一句中间提前生成标点、五言七言长度不稳定等问题。

- 藏头字必须严格出现在每句首位
- 每句需要固定五言或七言长度
- 标点位置需要稳定

约束生成方式

- 每句首字强制喂入藏头字
- `line_len` 控制五言或七言
- 句内屏蔽特殊 token 和标点
- 句末手动补，或。
- 整首诗共用 hidden state

藏头诗核心逻辑

```
for i, head in enumerate(heads):
    line = [head] # 每句首字强制为藏头字
    output, hidden = feed_word(model, word2ix[head], hidden, device)

    for _ in range(line_len - 1):
        next_idx, word = sample_word(output, ix2word, word2ix)
        line.append(word)
        output, hidden = feed_word(model, next_idx, hidden, device)

    punctuation = "." if i % 2 == 1 or i == len(heads) - 1 else " , "
    line.append(punctuation)
    if punctuation in word2ix:
        _, hidden = feed_word(model, word2ix[punctuation], hidden, device)
```

关键点

句内不让模型自由生成标点，而是在固定长度后统一补标点，因此格式比普通续写稳定。

藏头诗输出

五言藏头：深度学习

深山幽径可，
度地隔溪深。
学院时时见，
习门声渐闻。

七言藏头：丰川祥子

丰年今日在京都，
川路何妨在白云。
祥水自从名不见，
子孙难见好相过。

七言藏头：千早爱音

千里云山万里愁，
早秋城郭旧时秋。
爱君何事君为乐，
音信谁知此意稀。

五言藏头：长崎素世

长安风雨老，
崎岖傍空岑。
素彩含长纓，
世上还可怜。

总结

完成内容

- 完成唐诗数据预处理和 DataLoader 构建
- 实现两层 LSTM 语言模型
- 使用 LayerNorm 与 weight tying 改进输出层
- 记录训练 loss、PPL、学习率和梯度范数
- 实现普通续写与藏头诗生成

后续改进

- 加入重复惩罚，减少常见意象反复组合
- 在解码阶段加入韵脚约束
- 尝试更强的序列模型或预训练语言模型
- 进一步提升整首诗的主题连贯性