

实验四：基于 Transformer 的神经机器翻译

Chinese-English Neural Machine Translation

尧祥临 202518023406038

中国科学院大学 前沿交叉科学学院
2026 年春季学期 深度学习

实验任务

目标

基于 Transformer 实现中英神经机器翻译，完成数据处理、模型训练、测试翻译和 BLEU-4 评估。

实验要求

- 使用深度学习框架构建机器翻译模型
- 实现 Encoder-Decoder 结构
- 测试集 BLEU-4 大于 14

本次结果

- 训练日志共 57 个 epoch
- 最优开发集 loss 出现在第 47 轮
- 测试集 BLEU-4: **14.99**

数据集与预处理

- 数据集：NiuTrans 中英平行语料
- 训练集：100000 个句对
- 开发集：400 个句对
- 测试集：1000 个中文句子
- 参考译文：1000 个英文句子

处理方式

语料已经分词，代码中直接按空格切分；训练集、开发集和测试集统一编码后保存为 `processed.pt`。

特殊符号

`<pad>`、`<bos>`、`<eos>`、`<unk>` 用于 padding、序列边界和低频词处理。

词表与序列编码

项目	数值
源语言词表	30000
目标语言词表	22811
最小词频	2
最大序列长度	80


编码策略

每个源句和目标句都加入 `<bos>` 与 `<eos>`，超长句子截断，batch 内使用动态 padding。

为什么缓存

词表和 id 序列只需要构造一次，训练和评估复用同一份缓存，避免词表不一致。

整体流程




训练阶段

- 输入中文句子和英文前缀
- 预测目标端下一个 token

测试阶段

- 只输入中文句子
- 从 <bos> 开始逐步生成英文

Transformer 模型结构



主要配置

embedding dim = 256, heads = 8, FFN dim = 512, dropout = 0.1。

输出方式

Decoder 每个位置的隐藏状态经过线性层映射到英文词表，得到 token logits。

前向传播核心代码

```
def forward(self, src, tgt_input):
    src_key_padding_mask, tgt_key_padding_mask, tgt_mask = create_masks(
        src, tgt_input, self.src_pad_idx, self.tgt_pad_idx
    )

    src_emb = self.positional_encoding(self.src_embedding(src))
    tgt_emb = self.positional_encoding(self.tgt_embedding(tgt_input))

    memory = self.transformer.encoder(
        src_emb,
        src_key_padding_mask=src_key_padding_mask
    )
    output = self.transformer.decoder(
        tgt_emb, memory,
        tgt_mask=tgt_mask,
        tgt_key_padding_mask=tgt_key_padding_mask,
        memory_key_padding_mask=src_key_padding_mask
    )
    return self.generator(output)
```

Mask 与训练目标

Padding mask

忽略 batch 中为了补齐长度加入的 `<pad>`，避免模型把 padding 当成真实句子内容。

Causal mask

Decoder 预测第 t 个 token 时，只能看到 t 之前的目标端前缀，不能提前看到答案后文。

Teacher forcing

$$\text{Input} = y_0, \dots, y_{T-2}$$

$$\text{Target} = y_1, \dots, y_{T-1}$$

- 损失函数: CrossEntropy
- ignore_index 忽略 padding
- label smoothing = 0.1

项目	设置
Batch size	64
Epochs	60
Embedding dim	256
Encoder layers	3
Decoder layers	3
Attention heads	8

项目	设置
Optimizer	AdamW
Learning rate	5×10^{-4}
Weight decay	1×10^{-4}
Label smoothing	0.1
Scheduler	ReduceLROnPlateau
Gradient clip	1.0

BLEU-4 指标

BLEU 的核心

比较模型译文和参考译文之间的 n-gram 重合程度，BLEU-4 同时考虑 1-gram 到 4-gram。

$$\text{BLEU} = BP \cdot \exp \left(\sum_{n=1}^4 w_n \log p_n \right)$$

$$BP = \begin{cases} 1, & c > r, \\ e^{1-r/c}, & c \leq r. \end{cases}$$



实验结果

测试集共有 1000 个句子，当前模型语料级 BLEU-4 为：

14.99

- 满足实验要求：BLEU-4 > 14
- 单句 BLEU 波动较大，只作为辅助观察

训练过程




关键节点

- 第 1 轮 dev loss: 5.1639
- 第 30 轮 dev loss: 3.9208
- 第 47 轮 dev loss: **3.8580**
- 第 57 轮 dev loss: 3.8604

第 47 轮之后训练 loss 仍下降，但开发集 loss 基本不再改善，因此使用开发集最优模型做测试。

学习率与梯度范数




观察

- 开发集停滞后将学习率降低
- 梯度范数整体稳定在 1 附近
- 梯度裁剪避免异常更新

这次训练没有出现明显梯度爆炸，后期主要是小幅收敛和轻微过拟合之间的平衡。


译文长度分布



项目	平均长度
源句	24.77
参考译文	32.88
模型译文	29.93

模型译文整体接近参考译文，但略短一些，说明模型有时会省略修饰信息或生成偏保守的句子。

单句 BLEU 样例



样例观察

- 外交文本中的固定表达匹配较好
- 多个人名和多重转达关系容易混淆
- 数字、低频词和专名会带来 <unk>
- 短句上下文少，单句 BLEU 波动更明显

单句 BLEU 不能代替整体 BLEU，但能帮助观察模型到底错在什么地方。

翻译样例：高分句

样例 444, BLEU-4=35.27

源句：迟浩田首先转达了李鹏委员长对布马扎的诚挚问候和良好祝愿...

模型译文：chi haotian first conveyed president jiang zemin 's cordial regards and best wishes to president bouteflika ...

参考译文：chi haotian first conveyed chairman li peng 's sincere regards and good wishes to boumaza ...

模型角度

这类外交文本的固定表达比较常见，模型学到了类似“conveyed ... regards and best wishes”的模板；但句子里人名多、转达关系多，实体关系仍然容易混在一起。

翻译样例：低分句

样例 733, BLEU-4=7.99

源句：若如此, 还需要什麼神盾舰?

模型译文：if the aegis combat system is so advanced , what kind of aegis combat will be ?

参考译文：then why do we need aegis ships ?

模型角度

短句给 Encoder 的上下文较少，模型更依赖训练集中和“aegis”一起出现的常见搭配；贪心解码每一步选局部最高概率词，容易生成局部常见但整体不贴合源句的短语。

总结

完成内容

- 完成 NiuTrans 数据处理与缓存
- 实现 Transformer Encoder-Decoder
- 使用 teacher forcing 训练
- 实现贪心解码和 BLEU-4 评估

结果与不足

- 测试集 BLEU-4: **14.99**
- 复杂长句仍有实体关系混淆
- 词级词表导致低频词和数字不够稳定
- 可继续尝试子词分词和 beam search